

班 级 2202011
学 号 22009100015

西安电子科技大学

本科毕业设计论文



题 目 基于深度学习的

RGB-T 视觉目标跟踪研究与应用

学 院 电子工程学院

专 业 电子信息工程

学 生 姓 名 张沫潼

导 师 姓 名 李 洁

摘要

RGB-T 目标跟踪通过融合可见光与热红外两种模态的互补信息实现全天候鲁棒跟踪，其核心挑战在于两种模态的信息质量随光照、天气、遮挡等环境因素动态变化，跟踪器需要准确感知当前帧中各模态的可靠性并据此自适应地调整融合权重。然而，现有方法中的模态可靠性预测模块以端到端跟踪定位损失作为唯一训练信号，其优化目标被绑定在最终的边界框回归精度上，而非对模态质量本身的显式评估，导致可靠性预测在跨数据集测试时表现出系统性的过度置信偏差。

本文以 FMTrack 为基线模型，针对其多专家融合模块中可靠性预测的训练目标与语义意图错位问题，提出了模态质量可靠性校准模块，该模块包含三个核心组件，分别是独立温度缩放层，合成退化对比对齐机制，投影头。具体来说，独立温度缩放层为多专家融合模块各专家层分别设置可学习温度参数以压缩过置信的极端预测值；合成退化对比对齐机制通过程序化退化方式构造具有明确质量偏序关系的三元组样本，以间隔排序损失提供独立于跟踪定位目标的校准信号；两层 MLP 投影头将校准后的可靠性分数投影到融合权重空间，实现质量判断与权重决策的显式解耦。模态质量可靠性校准模块以后训练方式注入 FMTrack 推理流程，参数量极小，并且无需修改任何预训练参数。在 LasHeR、RGBT234 和 RGBT210 三个基准数据集上的实验表明，模态质量可靠性校准模块在所有数据集上均实现了性能提升，消融实验和置信度校准分析验证了各组件的有效性及后训练校准范式在多模态融合中的可行性。

关键词：RGB-T 目标跟踪 模态融合 可靠性校准 置信度校准 深度学习

ABSTRACT

RGB-T target tracking achieves all-weather robust tracking by fusing the complementary information of visible light and thermal infrared modalities. Its core challenge lies in the dynamic variation of both modalities' information quality due to environmental factors such as illumination, weather, and occlusion, requiring trackers to perceive the reliability of each modality and adaptively adjust the fusion strategy. However, existing methods train the modal reliability prediction module end-to-end with the tracking localization loss as the sole supervision signal, optimizing bounding box regression accuracy rather than directly modeling modal quality, leading to systematic overconfidence when evaluated on cross-dataset test sets.

This work takes FMTrack as the baseline model and, targeting the misalignment between the training objective and the semantic intent of the reliability prediction in its Multi-Expert Fusion Module, proposes a Modal Quality-aware Reliability Calibration module comprising three components: an independent temperature scaling layer that learns expert-layer-specific parameters to compress overconfident logit predictions; a synthetic degradation contrastive alignment mechanism that constructs triplets with explicit quality ordinal relationships through programmatic degradation and employs margin ranking loss to provide calibration-oriented supervision independent of the tracking objective; and a two-layer MLP projection head that maps calibrated reliability scores to fusion weights, achieving explicit decoupling between quality judgment and weight decision. The module is injected into the FMTrack inference pipeline via post-training with minimal parameters and without modifying any pre-trained weights. Experiments on LasHeR, RGBT234, and RGBT210 demonstrate consistent performance improvement across all datasets, and ablation analysis verifies the effectiveness and complementarity of each component in terms of generalization capability and applicability as a post-training calibration paradigm for multimodal fusion.

Keywords: RGB-T object tracking; modal fusion; reliability calibration; confidence calibration; deep learning

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	3
1.3 研究内容与创新点.....	8
第二章 FMTrack 基线方法.....	11
2.1 FMTrack 整体架构.....	11
2.2 频率感知交互网络 FIN.....	12
2.3 多专家融合模块 MEFM.....	14
2.4 MEFM 可靠性预测的局限性分析.....	15
2.5 本章小结.....	17
第三章 基于模态质量感知的可靠性校准方法.....	19
3.1 问题分析与设计动机.....	19
3.2 独立温度缩放层设计.....	21
3.3 合成退化对比对齐机制.....	22
3.4 MLP 投影头设计.....	25
3.5 后训练流程与实现细节.....	26
3.6 本章小节.....	27
第四章 实验结果与分析.....	29
4.1 实验数据集介绍.....	29
4.2 评估指标.....	30
4.3 实验设置.....	32
4.4 与现有方法的对比实验.....	33
4.5 消融实验.....	35
4.6 置信度校准质量分析.....	37
4.7 跟踪结果分析.....	38
4.8 本章小结.....	39
第五章 结论.....	41
致 谢.....	43
参考文献.....	45

第一章 绪论

1.1 研究背景与意义

视觉目标跟踪是计算机视觉领域中一项基础且关键的研究任务，其目标是在给定首帧目标外观的条件下，于后续视频帧中持续估计该目标的位置与尺度。经过数十年的发展，基于可见光图像的目标跟踪技术已经在算法精度与运行效率方面取得了长足进步，从早期的相关滤波方法到如今基于深度学习的端到端框架，跟踪器在标准评测场景中展现出越来越强的鲁棒性。然而，可见光成像本质上依赖场景中的环境光源，这一物理前提使得跟踪器的性能高度耦合于光照条件。当场景进入夜间低光照、浓雾散射、逆光过曝或剧烈光照变化等恶劣环境时，可见光图像中目标的外观信息会严重退化甚至完全丢失，导致跟踪器的定位精度急剧下降，难以满足实际应用的可靠性需求。图 1-1 展示了视觉目标跟踪任务的基本形式：在视频首帧中以边界框标注待跟踪目标（左），跟踪器在后续帧中持续输出目标的预测位置（右），即使目标经历位移、尺度变化和遮挡等干扰仍需保持稳定的定位输出。




图 1-1 视觉目标跟踪任务示意图

热红外成像提供了一条应对上述问题的重要途径。与可见光不同，热红外传感器捕获的是物体自身发出的热辐射信号，其成像过程不依赖外部光源，因而能够在完全黑暗、烟雾遮蔽或强光干扰等条件下稳定地呈现目标轮廓。这一特性赋予了热红外图像天然的全天候适应能力，使其在可见光失效的场景中仍能提供有效的目标位置线索。不过，热红外成像自身也存在明显的局限：由于成像原理基于温度差

异，热红外图像的空间分辨率通常较低，且几乎不包含纹理和颜色信息，这使得目标在热图像中的外观区分度有限，当多个热辐射特征相近的目标出现在同一区域时，容易出现定位失败的问题。图 1-2 展示了典型场景下 RGB-T 图像对的示例，可以直观观察到可见光与热红外图像在信息特征上的差异与互补性。



图 1-2 RGB-T 图像对示例

可见光与热红外两种模态在信息特征上的高度互补性，催生了 RGB-T 多模态目标跟踪这一研究方向。RGB-T 跟踪器同时接收空间对齐的可见光图像和热红外图像作为输入，通过设计合理的多模态融合机制，提取并整合两种模态各自的优势信息：可见光提供精细的纹理、颜色和边缘细节，热红外提供对光照鲁棒的目标存在性与轮廓信息，这两种信息互补从而使跟踪器在更广泛的环境条件下保持稳定的跟踪表现，这种融合策略在智能视频监控、自动驾驶感知、无人机目标搜索与导航、野外搜救等对全天候可靠性有严格要求的应用场景中，具有显著的实用价值。

RGB-T 跟踪面临的核心挑战在于两种模态的信息质量并非固定不变，而是随着环境条件的动态变化而此消彼长。在光照充足的白天场景中，可见光图像提供丰富且可靠的目标表征，此时热红外图像中目标与背景的温差可能很小，热图像的贡献有限；而在夜晚或极端天气下，情况则完全反转，可见光几乎不可用，热红外成为主导信息源。更复杂的情形是，在同一段视频序列中，模态质量可能因为局部遮挡、光照突变、目标运动状态变化等因素而逐帧波动。这意味着，采用固定权重或固定策略的融合方案都难以适应这种动态变化，跟踪器需要具备感知当前帧中各

模态信息质量的能力，并据此自适应地调整融合策略，才能在多变的实际环境中保持稳定的性能输出。

上述问题表明，模态可靠性建模在 RGB-T 跟踪中仍有重要的改进空间。从理论层面看，对该问题的深入研究有助于推动多模态视觉理解中信息质量评估与融合决策这一基础课题的发展，如何在多个信息源中动态识别可信信号并抑制噪声干扰这一方法不仅适用于 RGB-T 跟踪，也可推广至其他多模态感知任务。从应用层面看，更可靠的模态融合机制将直接提升 RGB-T 跟踪器在智能安防监控、自动驾驶夜间感知、无人机全天候巡检、灾难现场搜救等关键场景中的实际部署能力，为这些要求极高系统鲁棒性的应用提供更坚实的技术支撑。

1.2 国内外研究现状

视觉目标跟踪的研究从单模态可见光跟踪起步，经历了相关滤波、深度孪生网络和基于 Transformer 的统一框架三个主要技术阶段，而 RGB-T 多模态跟踪的发展脉络与之紧密交织，融合机制的设计始终受到基础跟踪框架演进的深刻影响。Feng 等人于 2024 年在 Information Fusion 上发表了针对 RGB-T 跟踪技术的系统性综述^[1]，对该领域近十年来的方法演进进行了全面梳理。该综述将现有 RGB-T 跟踪方法按融合策略的不同划分为像素级融合、特征级融合与决策级融合三大类别，并分别分析了各类方法在信息利用充分性、计算效率和系统复杂度方面的优劣权衡。通过在 LasHeR、RGBT234 等多个大规模基准上的横向实验对比，该综述指出特征级融合方法在表达能力与设计灵活性之间取得了最优的平衡，已成为当前 RGB-T 跟踪研究中采用最广泛的技术路线。同时，综述对当前方法的共性局限进行了总结，认为多数特征级融合方法在面对模态质量剧烈波动的场景时缺乏有效的自适应调节能力，如何实现对模态质量动态变化的实时感知与响应仍是该领域面临的开放性课题。在此基础上，置信度校准作为一项横跨机器学习多个分支的基础课题，也与多模态融合中的可靠性建模问题形成了密切关联。张天路等从深度学习的视角对 RGB-T 目标跟踪方法进行了系统综述^[2]，将现有方法按融合层级和注意力机制的差异进行分类，详细分析了从早期稀疏特征融合到近期基于 Transformer 的密集交互融合的技术演进路径，并在 LasHeR、RGBT234 等主流基准上对代表性方法进行了横向实验对比，指出当前方法在模态质量自适应感知方面仍存在普遍性不足。本节沿“单模态跟踪范式演进—RGB-T 多模态融合方法—置

信度校准理论”这一脉络，对相关研究进展进行系统梳理。

相关滤波方法构成了单模态目标跟踪技术演进的起点。Bolme 等人于 2010 年提出的 MOSSE 滤波器^[3]开创性地将目标跟踪建模为频域中的滤波器求解问题，通过在频域中学习一组滤波器系数使其与目标的相关输出逼近期望的高斯响应峰值，实现了极高的运行速度。孟璟等对目标跟踪算法从相关滤波到深度学习的发展历程进行了系统梳理^[4]，将跟踪方法按生成式模型和判别式模型两大范式进行分类，分析了各类方法在模型表达能力、在线更新策略和计算效率方面的优劣权衡，为理解后续深度孪生网络和 Transformer 跟踪架构的技术动机提供了清晰的背景参照。Henriques 等人于 2015 年发表的核化相关滤波器^[5] (Kernel Correlation Filter, KCF) 在此基础上引入循环移位样本生成策略和核技巧，将线性滤波器隐式提升到高维非线性特征空间，在不显著增加计算开销的前提下大幅提升了判别能力。KCF 配合方向梯度直方图 HOG 特征，在当时的跟踪基准上取得了精度与速度的良好均衡。然而，相关滤波范式的根本瓶颈在于对手工设计特征的依赖，这些底层描述子的表达能力存在天然上限，当目标经历剧烈形变、严重遮挡或复杂背景干扰时，跟踪器容易出现漂移。

深度孪生网络的出现标志着目标跟踪进入了以学习型特征为核心的新阶段。这一范式将跟踪建模为模板与搜索区域之间的相似度度量任务，通过深度卷积网络分别提取模板和搜索图像的特征表示，再经互相关运算生成响应图来定位目标。Li 等人提出的 SiamRPN++^[6]将 ResNet 等深层骨干网络引入孪生跟踪框架，并在特征互相关之后接入区域建议网络实现精确的边界框回归，在精度上大幅超越了相关滤波方法。但从架构角度审视，孪生网络存在一个结构性局限：模板分支和搜索分支在特征提取过程中彼此独立，跨分支信息交互被推迟到编码完成后的互相关阶段，限制了模型在特征提取早期阶段利用模板信息引导搜索区域编码的能力。

视觉变换器^[7] (Vision Transformer, ViT) 在目标跟踪中的应用从根本上改变了上述设计范式。OSTrack^[8]和 MixFormer^[9]等工作提出了“单流”跟踪架构，将模板帧和搜索帧的图像块序列拼接为统一的令牌序列，共同送入同一个变换器编码器处理。在自注意力计算中，每个令牌都能与序列中的所有其他令牌进行信息交互，特征提取和跨帧关系建模在变换器的每一层中同步完成，消除了孪生网络中手工设计的互相关操作。OSTrack 在 LaSOT、TrackingNet 和 GOT-10k 等多个大规模基准上刷新了性能记录，单流变换器架构凭借简洁的设计和强大的表达能力，已确立

为当前可见光目标跟踪的主流范式，也为后续的多模态跟踪研究提供了坚实的架构基础。

单模态跟踪框架的每一次范式转换都深刻影响了 RGB-T 多模态融合机制的设计思路。RGB-T 跟踪的技术演进以同期单模态框架为推动力，核心问题围绕“如何设计有效的跨模态信息交互与融合机制”展开，对模态信息质量差异的建模也逐步从隐式走向显式。早期的 RGB-T 跟踪方法主要在传统相关滤波或浅层网络框架下工作，对两个模态分别提取手工设计特征后通过简单拼接或加权求和合并为单一表示。这种策略没有对模态间信息质量差异做任何显式建模，当某一模态退化时融合结果中会混入大量噪声。深度学习的引入带来了更灵活的融合机制，一批工作采用双流卷积网络为两个模态分别设置独立的特征提取分支，通过注意力机制或门控网络进行跨模态交互。但这一阶段的多数方法仍采用静态或半静态的融合策略，融合权重在训练后基本固定或仅做局部自适应调整，缺乏对模态整体质量的全局判断能力。在多模态跟踪的另一条技术路线上，CMD^[10]发表于 CVPR 2023，通过构建跨模态蒸馏框架将一种模态中学到的判别性表示迁移到另一种模态的编码器中，增强各模态编码器对互补信息的隐式感知能力，其优势在于不需要在推理阶段执行显式的跨模态特征交互计算，但融合效果在很大程度上取决于蒸馏过程的设计和模态间知识的可迁移性。近年来 Hou 等人提出的 MTNet^[11]设计了模态感知网络以显式分离各模态的特有表示与共享表示，在保留模态独特判别信息的同时实现跨模态互补增强。

在将引入 RGB-T 跟踪的探索中，TBSI^[12] (Template-Bridged Search Interaction) 是一项具有代表性的工作，由 Hui 等人发表于 CVPR 2023。TBSI 建立在 ViT-Base 双流变换器编码架构上，通过在两条独立编码路径之间引入桥接令牌机制实现跨模态信息交换，以模板令牌作为“桥梁”在两个模态之间传递目标相关的前景信息，在避免引入冗余背景噪声的同时实现有效的跨模态信息传递。TBSI 在 LasHeR、RGBT234 和 RGBT210 三个主流基准上均取得了当时的最优性能，但其跨模态交互以均等方式对待两个模态的模板信息，缺乏对模态质量的显式判断机制。同期，Xiao 等人提出的 CAFormer^[13]通过跨模态调制注意力机制统一了自注意力与交叉注意力的计算框架，使模态间信息交互能够自适应地响应模态质量的动态变化。金静等提出了多模态特征融合跟踪网络 MMFFTN^[14]，通过设计跨模态注意力增强模块和自适应权重分配策略，在特征提取阶段即实现可见光与热红外信息的深度交

互，有效提升了复杂场景下的融合跟踪精度，在 RGBT234 和 LasHeR 上取得了具有竞争力的结果。

Xue 等人提出的 FMTrack^[15]，是近期 RGB-T 跟踪领域中在融合机制设计上做出系统性改进的重要工作，也是本文研究的核心基线方法。FMTrack 在单流变换器跟踪框架的基础上，提出了频率感知交互网络（Frequency-aware Interaction Network, FIN）和多专家融合模块（Multi-Expert Fusion Module, MEFM）两个核心组件，分别从特征交互维度和融合决策维度对 RGB-T 跟踪进行增强。FIN 利用快速傅里叶变换将双模态特征从空域变换至频域，在频域中对低频结构信息和高频细节信息分别设计独立的跨模态交互路径，使模型能够捕捉到空域卷积操作难以直接感知的全局结构互补信息。MEFM 则引入多个并行的融合专家子网络和一个可靠性预测子网络，后者对当前帧的双模态特征进行在线质量评估并据此动态选择融合策略，使跟踪器具备自适应调整融合行为的能力。FMTrack 凭借 FIN 和 MEFM 的协同作用，在 LasHeR、RGBT234 和 RGBT210 等基准数据集上超越了 TBSI，取得了新的最优性能。关于 FMTrack 的详细架构设计将在第二章中专门介绍。

尽管 MEFM 的设计意图在直觉上是合理的，其可靠性预测子网络的训练机制存在一个根本性的问题。在 FMTrack 的训练过程中，整个网络作为一个整体进行端到端训练，优化目标是最终的跟踪定位损失。可靠性预测子网络的参数更新完全由这个跟踪定位损失的梯度信号驱动，这意味着子网络被优化的目标是“输出何种可靠性分数能使最终的加权融合结果产生更准确的跟踪定位”，而非“当前帧中各模态的真实信息质量是多少”。前者是面向跟踪结果的隐式拟合目标，后者才是模态质量评估的本意。这两个目标在训练数据的分布范围内可能近似一致，但在语义层面是不同的。当模型面对与训练数据分布不同的测试场景时，这种语义错位的后果便会显现：可靠性预测子网络在训练集分布下拟合的隐式映射关系不再适用于新的分布条件，其输出的可靠性分数失去了对模态质量的真实指示意义。在实践中，这种分布偏移的典型表现是系统性的过度置信偏差，它的子网络倾向于对某一模态输出极高的置信度得分，即使该模态在当前帧中已严重退化。过高的错误置信度导致融合权重被大幅倾斜向退化模态，MEFM 中多个融合专家的加权组合因此被低质量信息主导，跟踪定位精度反而劣于简单的等权融合策略。尽管 Ding 等人提出的 QSTNet^[16]从令牌级质量感知角度出发，计算搜索区域中各令牌的质量权重以抑制低质量特征的干扰，但其质量评估仍以端到端训练方式进行，未解决置信度校

准的根本问题。这一训练目标与预期功能之间的语义错位，揭示了端到端训练范式在模态可靠性建模中的固有缺陷，构成了本文所提出的模态质量可靠性校准模块（Modal Quality-aware Reliability Calibration, MQRC）的根本设计动机。关于 MEFM 可靠性预测局限性的更详细分析见第二章第四节。

国内研究机构在 RGB-T 跟踪领域同样做出了重要贡献。安徽大学李程华教授团队构建了大规模 RGB-T 跟踪数据集 LasHeR，涵盖多种复杂场景和丰富的属性标注，已经成为该领域最重要的基准数据集之一。西安电子科技大学在跨模态特征对齐与轻量化跟踪网络设计方面持续开展研究工作，探索在有限计算资源约束下实现高效的多模态信息融合。余令仪等面向无人机应用场景提出了先验引导的 RGB-T 目标检测方法^[17]，利用空间先验信息约束跨模态特征对齐过程，在保持检测实时性的同时提升了小目标和密集目标场景下的检测精度，代表了 RGB-T 多模态技术向无人机平台落地应用的最新进展。中国科学院相关团队则在多模态感知的理论框架和系统集成方面进行了深入探索。这些国内研究力量的持续投入，使得中国学术界在 RGB-T 跟踪这一细分领域中保持了较高的国际影响力。

上述技术进展推动了多模态融合机制的不断深化，但与之密切相关的置信度校准问题同样值得关注。置信度校准是机器学习中一个具有长期研究历史的课题，其核心关注点在于使模型输出的概率估计能够真实反映其预测的实际正确率。Guo 等人揭示了一个重要现象：随着现代深度神经网络在模型容量上的不断增长，其分类精度持续提升的同时，置信度校准性能却显著恶化，高容量网络普遍倾向于对自身的预测赋予过高的置信度。Guo 等人在同一工作中提出的温度缩放方法^[18]因其极致的简洁性和出乎意料的有效性而成为该领域最具影响力的基线方法：在已训练好的模型 softmax 层之前将 logit 向量除以一个可学习的标量温度参数 T ，当 $T > 1$ 时概率分布趋于平滑从而抑制过度置信。整个校准过程不修改原始模型参数，仅引入一个额外标量参数在小规模验证集上优化，即可在多种网络架构上显著改善校准性能。在温度缩放之外，直方图分箱方法^[19]将置信度区间划分为离散桶并以桶内实际正确率作为校准值，保序回归^[20]则在保持置信度排序不变的约束下拟合单调映射函数，两者分别在非参数化和半参数化路线上提供了替代方案。王登豹等针对深度神经网络的置信度可校准性^[21]进行了系统研究，通过对比实验发现软标记、正则化等训练策略会影响模型的置信度可校准性，并揭示了模型容量与校准难度之间的内在关联，为本文采用后训练温度缩放范式进行模态可靠性校准提供了

理论依据。

近年来，多模态学习场景下的置信度校准开始受到关注。Zhang 和 Ma 等人在 2023 年 ICML 上发表的 CML^[22]工作揭示了多模态模型倾向于过度依赖某一主导模态的现象，并提出了正则化策略来约束跨模态的置信度分布，将校准粒度从类别级别提升到了模态级别。这一工作揭示了多模态场景中置信度失准的特殊机制，此后多模态学习社区中陆续出现了若干针对模态级别置信度估计的研究，探索如何在不同模态之间建立更合理的可靠性评估和融合权重分配。近期 Ding 等人提出的模板引导不确定性融合网络^[23]通过主观逻辑框架建模不同模态的不确定性，基于模板与搜索区域的相关性来动态评估各模态的可靠性，代表了显式质量建模方向的最新进展。

综合上述对单模态跟踪范式演进、RGB-T 多模态融合方法以及置信度校准理论的梳理，可以看到一个尚未得到充分解决的核心问题：现有 RGB-T 跟踪方法中的可靠性预测模块大多以端到端的方式与整个跟踪网络联合训练，其优化目标被绑定在最终的跟踪定位损失上。这种缺乏显式质量校准的隐式学习方式，在训练集分布内可能近似有效，但在跨数据集、跨场景的泛化测试中容易表现出过度置信。如何为模态可靠性预测引入独立于跟踪定位目标的显式校准机制，使融合权重的分配不仅在统计意义上最优、更在每一帧的语义层面上合理，是本文研究的核心出发点。

1.3 研究内容与创新点

本文围绕 RGB-T 多模态目标跟踪中模态融合可靠性建模这一核心问题展开研究。以 FMTrack 为基线跟踪器，针对其多专家融合模块 MEFM 中可靠性预测子网络存在的训练目标与语义意图错位问题，本文提出了一种模态质量可靠性校准模块 MQRC，旨在通过后训练校准的方式提升模态可靠性估计的合理性与泛化能力。研究的技术路线是：在保持 FMTrack 预训练参数完全冻结的前提下，仅在 MEFM 的可靠性预测输出端附加轻量级的校准组件，通过独立设计的训练目标和监督信号，对原始可靠性预测进行重新标定，使校准后的融合权重能够更准确地反映当前帧中各模态的真实信息质量。整个研究在 LasHeR^[24]、RGBT234^[25]和 RGBT210^[26]三个主流 RGB-T 跟踪基准数据集上进行系统评测，验证所提方法的有效性和跨数据集泛化能力。

本文的研究工作包含以下三个方面的设计贡献。

第一，本文提出了 MQRC 后训练校准框架，其核心思想是将模态可靠性估计的校准过程从端到端跟踪训练中解耦出来，作为一个独立的后处理阶段执行。具体而言，MQRC 模块接入在 FMTrack 已训练完毕的 MEFM 可靠性预测子网络输出之后，对其产生的原始可靠性分数进行重新映射。由于校准过程完全不触及 FMTrack 的预训练参数，原始跟踪器的特征提取能力和基础融合逻辑得以完整保留，MQRC 仅负责修正可靠性分数中因端到端训练偏差带来的置信度失真，这种后训练校准的设计范式具有较好的通用性。

第二，本文设计了合成退化对比对齐机制，用于解决模态质量校准中监督信号缺失的问题。在真实的 RGB-T 跟踪场景中，难以获得逐帧标注的模态质量标签，为绕过这一数据依赖，本文采用程序化退化方式构造伪监督信号：对训练样本中的某一模态施加可控的合成退化（如高斯模糊、噪声注入、亮度衰减等），人为制造已知的模态质量落差，并以此构建对比学习的训练对。在这种设计下，校准网络被训练去识别“退化模态应获得更低的可靠性分数，未退化模态应获得更高的可靠性分数”这一直觉上合理的偏序关系，而无需依赖精确的绝对质量数值标注。

第三，本文在架构层面实现了可靠性估计与融合权重决策的显式解耦。MQRC 模块内部由两个协作组件构成：一个独立的温度缩放层负责调整原始可靠性分数的分布尖锐度，压缩过度置信的极端预测值，使校准后的可靠性分数分布更加平滑合理；一个两层 MLP 投影头则将温度缩放后的可靠性分数进一步投影到融合权重空间，将“模态质量好坏的判断”与“融合权重如何分配”这两个语义上不同的决策步骤在网络结构上显式分开。这种解耦设计使得可靠性估计环节可以独立地以质量校准为目标进行优化，而融合权重的生成则在校准后的可靠性分数基础上完成，避免了端到端训练中两个目标相互干扰的问题。

本文共分为五章，各部分内容安排如下。第一章为绪论，阐述 RGB-T 多模态目标跟踪的研究背景与意义，系统综述单模态跟踪范式演进、RGB-T 多模态融合方法及置信度校准理论的国内外研究进展，分析当前模态融合可靠性建模中存在的核心问题，并介绍本文的研究内容与创新点。第二章对本文基线方法 FMTrack 的技术细节进行系统介绍，包括其基于 ViT-Base 的双流变换器编码框架、频率感知交互网络的频域分频段跨模态融合机制、多专家融合模块的动态可靠性加权策略，并对多专家融合模块中可靠性预测子网络训练目标与语义意图之间的错位问

题进行形式化分析，引出本文创新模块的设计动机。第三章详细阐述本文所提出的模态质量感知可靠性校准模块的设计原理与实现细节，依次介绍问题的形式化分析与设计动机、独立温度缩放层的设计、合成退化对比对齐机制的构造方式、MLP 投影头的结构设计，以及后训练流程与损失函数设计。第四章在 LasHeR、RGBT234 和 RGBT210 三个基准数据集上对所提方法进行全面的实验评测，包括与现有方法的性能对比、消融实验以及置信度校准质量分析。第五章为结论，对全文研究工作进行系统总结，概括方法设计与实验验证的主要成果。

第二章 FMTrack 基线方法

本文的研究以 FMTrack 为基线跟踪器，在其预训练模型基础上进行后训练校准。为使后续第三章对 MQRC 校准模块的设计阐述具备充分的技术背景，本章对 FMTrack 的整体架构和核心组件进行详细介绍，并在最后一节深入分析其可靠性预测机制的局限性，为 MQRC 的设计提供明确的问题界定。

2.1 FMTrack 整体架构

FMTrack 由 Xue 等人发表于 IEEE Transactions on Circuits and Systems for Video Technology (IEEE TCSVT) 2025 年，是近期 RGB-T 跟踪领域中在融合机制设计上做出系统性改进的重要工作。该方法在多个主流基准数据集上均超越了此前的最优方法，在 LasHeR、RGBT234 和 RGBT210 上取得了当时新的性能记录。FMTrack 建立在基于 ViT-Base 的双流变换器编码框架之上，为可见光和热红外两个模态分别维护独立的变换器编码路径，整体架构可以概括为“双模态输入→Patch Embedding→变换器编码→FIN 交互→MEFM 融合→预测头”的级联处理流程。在输入阶段，跟踪器分别对两种模态裁剪出模板图像块和搜索区域图像块，经 Patch Embedding 层进行分块与线性投影后形成各自的令牌序列，送入双流变换器编码器的对应分支进行特征编码。跨模态的信息交换由嵌入在特定编码层之间的 FIN 模块负责，最终的双模态特征融合决策则由 MEFM 模块在编码完成后统一执行，融合后的特征表示被送入预测头完成目标边界框的定位与回归。




图 2-1 FMTrack 整体架构图

FMTrack 的整体架构如图 2-1 所示。在输入阶段，FMTrack 同时接收一对空间

对齐的可见光图像和热红外图像。对于每种模态，跟踪器分别裁剪出模板图像块和搜索区域图像块，模板图像块以目标在首帧中的标注框为中心按一定比例裁剪，搜索区域图像块则在当前帧中以上一帧的预测位置为中心裁剪出更大范围的区域。裁剪后的图像块经过 Patch Embedding 层进行分块和线性投影：每张图像被划分为固定大小的非重叠图像块（patch），每个 patch 经线性投影映射为一个固定维度的令牌向量，再加上可学习的位置编码以保留空间位置信息。对于可见光模态，模板的令牌序列和搜索区域的令牌序列在序列维度上拼接，形成该模态的统一令牌序列；热红外模态执行同样的操作。至此，两个模态各自拥有一条独立的令牌序列，分别送入双流变换器编码器的对应分支。

变换器编码器采用双流架构，为可见光和热红外两个模态分别维护独立的编码路径。每条路径由多个标准变换器层堆叠构成，每层包含多头自注意力机制和前馈网络两个子模块。在自注意力计算中，同一模态内的模板令牌和搜索区域令牌能够相互交互，使特征提取与模板-搜索匹配在每一层中同步完成，继承了 OTrack 等单流跟踪器的设计优势。两条编码路径共享相同的网络结构但维护各自独立的参数，在编码过程中默认互不干扰。跨模态的信息交换由嵌入在特定变换器层之间的 FIN 模块负责，而最终的双模态特征融合决策则由 MEFM 模块在编码完成后统一执行。这种“模态内独立编码+模态间显式交互”的架构设计，在保持各模态特征独立性的同时通过专门设计的交互模块引入跨模态互补信息，在特征保真和信息融合之间取得了有效的平衡。

在编码器输出端，两个模态的搜索区域特征经 MEFM 融合后生成统一的融合特征表示，该表示被送入预测头进行最终的目标定位。预测头采用与 OTrack 类似的设计，包括分类分支和边界框回归分支：分类分支预测搜索区域中每个位置为目标中心的概率，回归分支在预测的目标中心位置处输出边界框的偏移和尺度。两个分支的输出共同确定当前帧中目标的最终预测边界框。

2.2 频率感知交互网络 FIN

频率感知交互网络 FIN 是 FMTrack 在跨模态特征交互层面的核心创新。FIN 的设计出发点基于一个关键的信号处理洞察：传统的空域卷积操作在有限感受野范围内对特征进行局部聚合，对目标的全局结构信息（如整体轮廓、对称形状）的捕捉能力有限，而频域变换天然能够将图像的全局结构特征与局部细节特征分离

到不同的频率分量中。FIN 正是利用这一性质，在频域中为不同层次的跨模态信息交互设计了专门的处理路径。




图 2-2 FIN 模块结构示意图

FIN 模块的结构如图 2-2 所示。FIN 模块被嵌入在双流变换器编码器的特定层之间，接收两个模态在当前编码阶段的特征图作为输入。其处理流程包含“空域到频域变换—频段跨模态交互—频域到空域逆变换”三个阶段。

在第一阶段，FIN 对两个模态的特征图分别施加二维快速傅里叶变换（FFT），将空域特征变换至频域表示。频域变换后，每个模态的特征图被表示为复数值的频谱矩阵，其中低频分量集中于频谱中心区域，高频分量分布于频谱边缘。低频分量主要编码目标的整体结构信息，包括轮廓、形状、大致亮度分布等宏观特征；高频分量则主要编码局部细节信息，如纹理、边缘、尖锐过渡等微观特征。FIN 通过频率阈值将频谱分离为低频子带和高频子带两个部分。

在第二阶段，FIN 对低频和高频分量分别设计了独立的跨模态交互路径。在低频路径中，两个模态的低频结构特征通过跨模态注意力机制进行融合。可见光模态中与目标整体形状和颜色轮廓相关的低频信息，与热红外模态中与目标热辐射轮廓相关的低频信息，在此进行互补增强。这种低频层面的交互使跟踪器能够在模态的结构信息退化（例如夜间可见光目标轮廓模糊）时，从另一个模态的低频分量中获取补偿。在高频路径中，两个模态的高频细节特征同样进行跨模态交互。可见光模态中的纹理和边缘信息与热红外模态中的温度梯度边界信息在此实现互补，增强目标与背景之间的判别边界。高频路径的交互对于热交叉场景（目标与相邻物体温度接近导致热红外中目标边界模糊）尤为关键，可见光中保留的纹理细节能够帮助区分热红外中难以分辨的相邻目标。两条独立路径的分离设计避免了不同尺

度特征之间的相互干扰，即全局结构信息的交互不会被高频噪声所污染，局部细节信息的增强也不会受到低频成分的过度平滑。

在第三阶段，经跨模态交互增强后的低频和高频分量重新合并，通过二维逆快速傅里叶变换（IFFT）转换回空域特征表示。变换回空域后的特征图在保持与原始特征相同的空间结构和维度的同时，已经编码了来自对方模态的互补信息。增强后的特征图被送回各自模态的变换器编码路径中，继续后续层的特征提取。

值得一提的是，FIN 的实现依赖 `mmcv-full` 库中的部分 CUDA 自定义算子来加速频域变换和注意力计算。`mmcv-full` 对 CUDA 编译工具链版本有严格要求，在不同硬件环境下的编译兼容性可能存在差异，这一工程层面的约束在本文的复现实验中带来了需要额外处理的兼容性问题（详见第四章实验设置部分）。

2.3 多专家融合模块 MEFM

多专家融合模块 MEFM 是 FMTrack 在融合决策层面的核心贡献，其设计目标是解决静态融合策略无法适应模态质量动态变化的问题。与 FIN 负责特征层面的跨模态交互不同，MEFM 作用于编码器输出端，负责将两个模态的编码特征整合为最终送入预测头的统一融合表示。




图 2-3 MEFM 模块结构图

MEFM 模块的结构如图 2-3 所示。MEFM 包含两个核心子组件：多个并行的融合专家子网络和一个可靠性预测子网络。

融合专家子网络的设计思想源自混合专家模型（Mixture of Experts, MoE）的理念。MEFM 设置了多个结构相同但参数独立的轻量级融合子网络，每个子网络

接收来自两个模态的编码特征作为输入，以各自不同的方式组合双模态信息生成一种融合结果。在训练过程中，不同的专家自然地学习到不同的融合偏好：有的专家在融合中赋予可见光特征更高的权重，适合可见光质量优于热红外的场景；有的专家侧重热红外特征的贡献，适合夜间或低光照场景；还有的专家对两种模态的特征进行近似等权的融合，适合两种模态质量相近的场景。每个专家的输出都是一个完整的融合特征图，代表一种特定的融合策略在当前帧条件下的处理结果。

可靠性预测子网络是 MEFM 实现动态融合策略选择的关键机制。该子网络以当前帧的双模态特征作为输入，首先通过全局平均池化将高维特征图压缩为全局特征向量，然后经过全连接层处理后输出一个二维向量 $r = [r_{rgb}, r_{tir}]$ ，其中 r_{rgb} 和 r_{tir} 分别表示可见光模态和热红外模态的可靠性 logit 值。这两个标量经 softmax 归一化生成融合权重：

$$w_m = \frac{\exp(r_m)}{\sum_{m' \in \{rgb, tir\}} \exp(r_{m'})}, \quad m \in \{rgb, tir\} \quad (2-1)$$

归一化后的权重满足 $w_{rgb} + w_{tir} = 1$ 且 $w_m \in (0,1)$ ，被用于对各融合专家的输出进行加权线性组合，生成最终的融合特征表示：

$$F_{fused} = \sum_i \alpha_i(w_{rgb}, w_{tir}) \cdot F_{expert_i} \quad (2-2)$$

其中 α_i 为第 i 个专家在给定可靠性权重下的组合系数， F_{expert_i} 为第 i 个专家的输出。通过可靠性权重调控各专家的贡献比例，MEFM 的融合输出能够根据当前帧的模态质量状况动态调整：当可见光质量高时，侧重可见光的专家获得更大权重；当热红外更可靠时，权重向侧重热红外的专家倾斜。

MEFM 的设计意图是清晰的：通过可靠性预测子网络对当前帧的模态质量进行在线评估，然后根据评估结果动态选择最适合当前模态质量状况的融合策略。这种多专家加权的融合范式在理论上赋予了模型根据当前帧条件自适应调整融合行为的能力，相较于 TBSI 等方法的固定交互策略是一个有意义的推进。

2.4 MEFM 可靠性预测的局限性分析

尽管 MEFM 的多专家融合架构在设计理念上具有明确的合理性，其可靠性预测子网络的训练机制存在一个从训练目标层面即可辨识的根本性问题，这一问题

直接构成了本文第三章 MQRC 模块的设计动机。

在 FMTrack 的训练过程中, 包括骨干编码器、FIN 模块、MEFM 以及目标定位头的整个网络作为一个整体进行端到端训练, 优化目标是跟踪定位损失 $\mathcal{L}_{track}$ (由分类损失和边界框回归损失组成)。可靠性预测子网络的参数 θ_r 通过反向传播接收来自 $\mathcal{L}_{track}$ 的梯度信号进行更新:

$$\theta_r^* = \arg \min_{\theta_r} \mathbb{E}_{(x,y) \sim \mathcal{D}_{train}} [\mathcal{L}_{track}(f(x; \theta_{all}), y)] \quad (2-3)$$

其中 x 表示输入的双模态图像对, y 表示对应的真实边界框标注, θ_{all} 包含网络全部参数, f 表示网络的前向推理映射。此处的关键观察在于: θ_r 的优化目标并非直接约束 r_{rgb} 和 r_{tir} 去反映两个模态各自的图像质量, 而是要求这两个值经过 softmax 和专家加权后使最终的跟踪定位结果尽可能准确。可靠性子网络学到的是面向跟踪结果的隐式映射, 而非面向模态质量的显式评估。

从期望功能的角度审视, 一个理想的模态可靠性预测器应当满足的语义约束是: 对于模态 m 的图像质量 q_m , 可靠性分数应与质量保持单调一致性, 即满足 $q_{rgb} > q_{tir} \Rightarrow r_{rgb} > r_{tir}$ 。然而, 端到端训练中对 θ_r 的优化目标 $\min_{\theta_r} \mathcal{L}_{track}$ 并未对这一单调一致性施加任何显式约束。可靠性分数只要能使最终的加权融合特征在定位头处产生更低的损失即可, 至于这些分数是否真正反映了模态质量的相对高低, 在训练目标中没有保障机制。

在训练集 $\mathcal{D}_{train}$ 的数据分布范围内, 跟踪精度优化与模态质量判断之间存在近似一致性, 即在大量帧对上取期望时, 能够区分模态质量高低的可靠性分数分配方案统计上也倾向于产生更好的跟踪定位结果。但这种对齐是隐式的、统计意义上的, 而非逐帧级别的精确保证。当测试数据的分布与训练数据出现偏移时 ($\mathcal{D}_{test} \neq \mathcal{D}_{train}$), 上述隐式对齐所依赖的统计规律不再成立。在 RGB-T 跟踪的实际应用中, 分布偏移是常态而非例外: 不同数据集之间在场景类型、传感器特性、季节气候条件以及标注粒度等方面均存在显著差异。

这种偏离在实践中最典型的表现形态是系统性的过度置信: softmax 归一化后的融合权重出现 $\max(w_{rgb}, w_{tir}) \rightarrow 1$ 的趋势, 即网络倾向于将几乎全部的融合权重集中分配给某一个模态。当这种极端权重分配恰好与实际模态质量一致时并无问题, 但当质量判断出现错误时, 融合结果被严重退化的低质量模态所主导, 多模态

融合的鲁棒性优势完全丧失。从信息论的角度看，过度置信意味着融合决策的有效信息熵过低，系统丧失了多模态冗余所本应提供的容错空间。

这一训练目标与预期功能之间的语义错位，揭示了端到端训练范式在模态可靠性建模中的固有缺陷：可靠性预测被绑定在跟踪定位损失上进行联合优化，缺少针对模态质量本身的独立监督信号。正是这一分析构成了第三章所提出的 MQRC 模态质量可靠性校准模块的根本设计动机，即将可靠性估计从端到端训练中解耦出来，以独立的校准目标和专门设计的监督信号对原始可靠性预测进行后训练修正。

2.5 本章小结

本章对 FMTrack 基线方法进行了系统介绍。首先概述了 FMTrack 基于 ViT-Base 双流变换器的整体架构设计；其次详细分析了频率感知交互网络 FIN 在频域中实现分频段跨模态信息交互的机制；随后介绍了多专家融合模块 MEFM 通过可靠性预测子网络实现动态融合策略选择的工作原理；最后从训练目标层面对 MEFM 可靠性预测子网络存在的语义错位问题进行了形式化分析，揭示了端到端训练范式导致的系统性过置信缺陷，明确了本文 MQRC 模块的设计动机。

第三章 基于模态质量感知的可靠性校准方法

3.1 问题分析与设计动机

第二章对 FMTrack 基线方法的详细介绍揭示了 MEFM 可靠性预测子网络在训练目标层面存在的语义错位问题。本节将这一问题从定性描述推进到形式化层面，通过严格的数学语言刻画其产生机制与后果，从而为后续 MQRC 模块的设计提供清晰的理论动机。

在 FMTrack 的 MEFM 模块中，可靠性预测子网络以当前帧的双模态特征经过全局池化和全连接层压缩后的表示作为输入，输出一个二维向量 $r = [r_{rgb}, r_{tir}] \in \mathbb{R}^2$ ，其中 r_{rgb} 和 r_{tir} 分别表示可见光模态和热红外模态经全局平均池化与全连接层映射后得到的可靠性 logit 值，数值越大表示该模态被预测为越可靠。这两个标量随后被送入 softmax 函数进行归一化，生成用于加权各融合专家输出的融合权重：

$$w_m = \frac{\exp(r_m)}{\sum_{m' \in \{rgb, tir\}} \exp(r_{m'})}, \quad m \in \{rgb, tir\} \quad (3-1)$$

归一化后的权重满足 $w_{rgb} + w_{tir} = 1$ 且 $w_m \in (0,1)$ ，被用于对 MEFM 中多个融合专家的输出进行线性组合。整个 FMTrack 网络作为一个端到端系统进行联合训练，优化目标是跟踪定位损失 $\mathcal{L}_{track}$ （由分类损失和边界框回归损失组成）。可靠性预测子网络的参数 θ_r 通过反向传播接收来自 $\mathcal{L}_{track}$ 的梯度信号进行更新：

$$\theta_r^* = \arg \min_{\theta_r} \mathbb{E}_{(x,y) \sim \mathbb{D}_{train}} [\mathcal{L}_{track}(f(x; \theta_{all}), y)] \quad (3-2)$$

其中 x 表示输入的双模态图像对， y 表示对应的真实边界框标注， θ_{all} 包含网络全部参数， f 表示网络的前向推理映射。此处的关键在于： θ_r 的优化目标并非直接约束 r_{rgb} 和 r_{tir} 去反映两个模态各自的图像质量，而是要求这两个值经过 softmax 和专家加权后使最终的跟踪定位结果尽可能准确。可靠性子网络学到的是一种面向跟踪结果的隐式映射，而非面向模态质量的显式评估。

从期望功能的角度审视，一个理想的模态可靠性预测器应当满足如下语义约束：对于模态的图像质量 q_m ，即综合反映该帧中目标在模态 m 下可辨识程度的抽象度量，可靠性分数应与质量保持单调一致性，即满足当 $q_{rgb} > q_{tir}$ 时有 $r_{rgb} > r_{tir}$ 。

然而，端到端训练中对 θ_r 的优化目标 $\min_{\theta_r} \mathcal{L}_{track}$ 并未对这一单调一致性施加任何显式约束。 θ_r 的更新完全由跟踪定位损失的梯度驱动，可靠性分数只要能使最终的加权融合特征在定位头处产生更低的损失即可，至于这些分数是否真正反映了模态质量的相对高低，在训练目标中没有保障机制。

在训练集 $\mathcal{D}_{train}$ 的数据分布范围内，跟踪精度优化与模态质量判断之间存在近似一致性。训练集包含足够数量且分布稳定的样本，在大量帧对上取期望时，能够区分模态质量高低的可靠性分数分配方案统计上也倾向于产生更好的跟踪定位结果。因此 $\min \theta_r \mathcal{L}_{track}$ 在训练集上的优化引导了 r_m 与 q_m 之间的近似对齐。然而，这种对齐是隐式的、统计意义上的，而非逐帧级别的精确保证，当测试数据的分布与训练数据出现偏移时（ $\mathcal{D}_{test} \neq \mathcal{D}_{train}$ ），上述隐式对齐所依赖的统计规律不再成立。在 RGB-T 跟踪的实际应用中，分布偏移是常态而非例外：不同数据集之间在场景类型、传感器特性、季节气候条件以及标注粒度等方面均存在显著差异。

这种偏离在实践中最典型的表现形态是系统性的过度置信：softmax 归一化后的融合权重出现 $\max(w_{rgb}, w_{tir}) \rightarrow 1$ 的趋势，即网络倾向于将几乎全部的融合权重集中分配给某一个模态。当这种极端权重分配恰好与实际模态质量一致时并无问题，但当质量判断出现错误时，融合结果被严重退化的低质量模态所主导，多模态融合的鲁棒性优势完全丧失。从信息论的角度看，过度置信意味着融合决策的有效信息熵过低，系统丧失了多模态冗余所本应提供的容错空间。

基于上述形式化分析，MQRC 模块的设计遵循三条原则。第一条是非侵入性：不修改 FMTrack 任何预训练参数，所有校准操作在可靠性预测输出之后、融合权重生成之前的环节进行，完整保留原始模型的特征提取能力和基础判别性能。第二条是轻量级：校准模块的参数量控制在极小规模内，训练过程不依赖大规模数据或长时间迭代。第三条也是最核心的原则：为可靠性预测引入独立于跟踪定位目标的校准信号。前述分析表明，将可靠性预测绑定在 $\mathcal{L}_{track}$ 上是导致语义错位和过置信的根本原因，校准信号必须直接针对模态质量本身的相对高低进行约束。这三条原则共同规定了 MQRC 的设计边界：一个在 FMTrack 冻结参数之上进行后训练的轻量级校准模块，其训练目标能够显式地将可靠性分数与模态质量的偏序关系对齐。MQRC 校准模块的整体架构如图 3-1 所示。




图 3-1 MQRC 校准模块整体架构图

3.2 独立温度缩放层设计

MQRC 模块的第一个组件是面向双模态场景设计的独立温度缩放层，其功能是对可靠性预测子网络输出的原始 logit 值进行分布形态调整，压缩过度置信产生的极端预测值。

温度缩放的基本思想源自 Guo 等人在分类网络置信度校准中的经典工作：其核心功能是在不改变原始模型任何参数的前提下，通过一个全局共享的可学习标量参数对模型输出的概率分布进行钝化或锐化调节，从而在模型存在过度置信倾向时，该参数能够自动学得使概率分布趋于平滑的取值，压制不合理极端预测；反之则增强区分度。这种仅含一个参数的方法在多种网络架构和数据集上均能显著改善校准性能的事实，为本文的校准方案提供了重要的方法论启示。然而，经典温度缩放所有类别共享同一温度参数的前提在多模态可靠性校准场景下并不适用。在 RGB-T 跟踪中，可见光模态的可靠性分数对光照变化高度敏感，在夜间或逆光场景中容易出现不合理的高置信度；热红外模态的可靠性分数则主要受环境温度均匀性和传感器噪声水平影响，其过置信模式与可见光截然不同。由于可见光受制于环境光源，而热红外受制于目标与背景的温度差，导致其可靠性分数的动态范围和偏差方向也各不相同。如果两个模态共享同一温度参数，校准效果将偏向其中统计权重较大的模态，另一模态的置信度偏差得不到充分矫正。

基于此，本文为 MEFM 中四个专家层分别设置独立的温度参数。在参数化方式上，由于温度参数必须严格为正，本文采用对数空间参数化：以 τ_i 作为可学习参数，温度通过指数映射 $T_i = \exp(\tau_i)$ 获得，保证无论 τ_i 取何值 T_i 始终为正。校准后的

logit 值为:

$$\tilde{r}_{i,j} = \frac{r_{i,j}}{T_i} = \frac{r_{i,j}}{\exp(\tau_i)}, \quad i = 1, \dots, 4, j = 1, \dots, 8 \quad (3-3)$$

校准后的融合权重由校准 logit 经 softmax 归一化生成:

$$\tilde{\mathbf{r}}_i = \frac{\mathbf{r}_i}{T_i} \in \mathbb{R}^8, \quad i = 1, \dots, 4 \quad (3-4)$$

四个可学习参数的初始值 τ_i 均设为0, 对应 T_i 均为 1.0, 此时温度缩放层等价于恒等变换。这种恒等初始化确保校准训练从 FMTrack 原始性能出发, 任何参数更新都是原有性能基础上的增量调整。训练完成后, $T_i > 1$ 意味着该模态 logit 被压缩、融合权重向均匀分布靠近, 即校准过程判断该专家存在过置信倾向; $T_i < 1$ 意味着 logit 被放大、权重更趋极端, 即原始预测对该专家层的置信度不足。各专家层各自学得不同温度值, 使校准过程能够分别适应不同专家层在融合决策中各自不同的过置信偏差规律。

3.3 合成退化对比对齐机制

温度缩放层的参数需要通过梯度优化确定最优取值, 核心难点在于监督信号的来源。经典温度缩放以验证集上的真实类别标签为监督, 但在模态可靠性校准场景下为每帧图像标注精确的模态质量数值既不可行也难以保证一致性。MQRC 的合成退化对比对齐机制正是为绕过这一困难而设计的: 通过程序化的图像退化操作构造具有明确质量偏序关系的样本组, 将绝对质量标注的需求转化为相对质量排序的弱监督信号。

合成退化操作的设计遵循两条准则: 退化类型应覆盖对应模态在真实场景中最常见的质量退化模式, 使合成退化与真实退化具有语义近似性; 每种退化应配有连续可控的强度参数以构造分级样本。

每种退化划分为低强度和高强度两个等级: 低强度退化后目标区域仍清晰可辨, 图像整体质量虽有下降但不影响基本的目标识别; 高强度退化后目标出现明显的模糊、遮挡或信息丢失, 图像质量的退化肉眼可感。值得注意的是, 上述退化操作的设计并非追求对真实退化的精确模拟, 而是旨在以最低的实现复杂度构造出质量具有明确高低之分的样本对, 即只要退化后的图像确实比原始图像“更差”, 就足以为偏序监督提供有效的训练信号。这种宽松的要求使得退化操作的具体实现细节对最终校准效果的敏感度较低, 增强了方法的鲁棒性。

针对可见光模态，本文设计了四种退化操作：1) 随机矩形遮挡。在目标区域附近叠加纯色矩形块，模拟目标被前景物体部分遮蔽的场景，以遮挡面积占目标区域的比例作为强度参数；2) 高斯噪声叠加。向图像像素添加零均值高斯随机噪声，模拟低光照条件下传感器信噪比下降导致的图像质量退化，以噪声标准差作为强度参数；3) 低光亮度压缩。对图像亮度通道施加线性衰减，模拟夜间或阴暗环境下目标可见度降低的场景，以亮度衰减系数作为强度参数；4) 运动模糊。沿随机方向施加线性运动核卷积，模拟相机抖动或目标快速运动产生的拖影效应，以卷积核长度作为强度参数。



图 3-2 RGB 模态合成退化示例

针对热红外模态，本文设计了三种退化操作：1) 对比度均匀压缩。将灰度动态范围向中值方向压缩，模拟环境温度均匀时目标与背景温差减小导致轮廓“淡化”的现象，以压缩比例作为强度参数；2) 条纹噪声叠加。向图像添加水平方向的周期性亮度条纹，模拟非制冷红外探测器中常见的固定图案噪声伪影，以条纹幅度作为强度参数；3) 随机像素丢失。将图像中一定比例的像素值随机置零，模拟传感器像元失效或数据传输丢包造成的信息缺失，以丢失比例作为强度参数。




图 3-3 TIR 模态合成退化示例

图 3-2 和图 3-3 分别展示了 RGB 和 TIR 模态各退化操作在低强度和高强度两个等级下的视觉效果。每行从左至右依次为原始图像、低强度退化结果和高强度退化结果。可以观察到，低强度退化后目标区域仍清晰可辨，图像整体质量虽有下降但不影响基本的目标识别；高强度退化后目标出现明显的模糊、遮挡或信息丢失，图像质量的退化肉眼可感。这种分级退化策略确保了三元组样本之间存在明确且可区分的质量偏序关系，为排序损失提供了有效的监督信号。

在退化操作的基础上，本文构造三元组样本为温度参数的优化提供偏序监督信号。对于训练集中的每帧双模态图像对，对被选中退化的模态 m 生成三个版本：原始未退化版本、低强度退化版本和高强度退化版本。三个版本分别经过 FMTrack 冻结编码器和 MEFM 可靠性预测子网络提取原始 logit 值，再经温度缩放层得到校准后的可靠性分数。由退化操作的构造方式可知，三个版本之间存在确定的质量偏序关系：原始版本的模态质量最高，低强度退化版本次之，高强度退化版本最低。这一偏序关系应当在校准后的可靠性分数中得到忠实反映，即满足 $\widehat{r}_m^{(0)} > \widehat{r}_m^{(low)} > \widehat{r}_m^{(high)}$ 。需要强调的是，这里构造的是相对偏序而非绝对数值标注，校准网络只需学会“退化越严重则分数越低”这一方向性判断，不需要学会精确预测退化程度的具体数值。

为将这一偏序约束转化为可微的训练损失，本文采用间隔排序损失（Margin

Ranking Loss)。对于模态 m 的三元组，排序损失定义为：

$$\mathcal{L}_{rank}^m = \text{MRL}\left(\widehat{r_m^{(0)}}, \widehat{r_m^{(low)}}, \delta\right) + \text{MRL}\left(\widehat{r_m^{(low)}}, \widehat{r_m^{(high)}}, \delta\right) \quad (3-5)$$

其中间隔排序损失函数的具体形式为：

$$\text{MRL}(a, b, \delta) = \max(0, -(a - b) + \delta) \quad (3-6)$$

δ 为间隔阈值，规定相邻质量等级的校准可靠性分数之间必须保持的最小差距。当 $a - b \geq \delta$ 时损失为零，否则梯度驱动温度参数调整使分数差异增大。 δ 在本文中设为 0.2，在保证偏序区分度与避免数值不稳定之间取得平衡。两个模态分别构造各自的退化三元组并独立计算排序损失，总排序损失为二者之和：

$$\mathcal{L}_{rank} = \mathcal{L}_{rank}^{rgb} + \mathcal{L}_{rank}^{tir} \quad (3-7)$$

这一设计使各专家层的温度参数由两个模态的退化三元组共同驱动更新，每个模态的退化信号独立提供偏序约束，避免不同退化来源之间的梯度信号相互干扰。从信号性质看， $\mathcal{L}_{rank}$ 提供的是与跟踪定位目标完全独立的校准信号：它不关心跟踪框的定位精度，只关心校准后的可靠性分数是否忠实编码了模态质量的相对高低。这正是 3.1 节所要求的“独立于跟踪定位目标的校准信号”，从根本上将可靠性估计的优化方向从“间接服务于跟踪精度”转向“直接对齐模态质量偏序”。

3.4 MLP 投影头设计

温度缩放层输出的校准 logit 张量 $\tilde{\mathbf{r}} \in \mathbb{R}^{32}$ 编码了经过置信度调整后的模态质量判断，但将其直接通过 softmax 转化为最终融合权重隐含了一个较强的假设：校准分数空间中的数值关系可以线性映射到融合权重空间的决策关系。实际情况远比这一假设复杂，不同数据集和场景下模态质量得分与最优融合权重之间可能存在阈值效应或饱和效应等非线性关系。为捕捉这种映射复杂性，MQRC 在温度缩放层之后引入一个两层全连接网络作为投影头。

输入层接收校准后的八维专家选择权重向量，经第一层全连接变换投影到 16 维隐层空间并通过 ReLU 激活引入非线性：

$$\mathbf{h} = \text{ReLU}(\mathbf{W}_1 \tilde{\mathbf{r}}_i^\top + \mathbf{b}_1) \quad (3-8)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{16 \times 8}$ ， $\mathbf{b}_1 \in \mathbb{R}^{16}$ 。第二层全连接变换将隐层表示投影回八维空间：

$$\hat{\mathbf{r}}_i = \tilde{\mathbf{r}}_i + (\mathbf{W}_2 \mathbf{h} + \mathbf{b}_2) \quad (3-9)$$

其中 $\mathbf{W}_2 \in \mathbb{R}^{8 \times 16}$ ， $\mathbf{b}_2 \in \mathbb{R}^8$ ，隐层维度选取 16 是在表达能力与过拟合风险之

间权衡的结果：对于仅有 8 维输入的映射任务，16 维隐层已提供足够的非线性拟合容量，更高维度反而增加过拟合风险。

投影头在 MQRC 架构中实现了重要的功能解耦：温度缩放层专注于校准可靠性分数的绝对尺度和分布形态，投影头则负责将校准后的质量判断转化为具体的融合权重数值，学习从质量空间到决策空间的映射。如果取消投影头而直接对温度缩放后的分数送回原始流程，温度参数不仅需要校准置信度分布，还要兼顾融合权重的绝对数值是否合适，两个不同语义层面的优化目标被压缩到仅有的 4 个标量参数上，优化自由度严重不足。投影头提供了缓冲层，使温度参数可以专注于校准，质量判断到融合权重的映射由投影头独立承担。

3.5 后训练流程与实现细节

MQRC 模块的训练以 FMTrack 完整的预训练模型为起点，采用严格的后训练范式：加载 FMTrack 全部预训练权重后，遍历模型所有参数并将 `requires_grad` 设为 `False`，完全冻结原始模型参数。冻结操作覆盖骨干编码器、FIN 模块、MEFM 模块以及定位头的全部权重和偏置，确保校准训练的梯度信号不会回传至 FMTrack 的任何原始参数。

模型冻结完成后，MQRC 通过前向 hook (forward hook) 机制注入到 FMTrack 的推理流程中。本文在 MEFM 内部可靠性预测子网络的输出层注册一个 `forward hook` 函数，该函数在每次前向传播执行到该层时被自动调用，截获可靠性预测子网络输出的原始 logit 张量。该张量形状为 $[B, 32]$ ，该张量形状为 $[B, 32]$ ，编码了 4 个专家层各 8 个操作的选择权重。钩子函数将截获的张量送入温度缩放层和 MLP 投影头处理，用校准后的融合权重 $[\tilde{w}_{rgb}, \tilde{w}_{tir}]$ 替换原始权重后继续后续前向传播。这种基于钩子的注入方案具有完全的非侵入性：不修改 FMTrack 的任何模型类定义或源代码文件，不改变模块层次结构，预训练权重文件的加载保存流程完全不受影响。为验证注入方案的数值正确性，本文在温度参数初始化为 $T_{rgb} = T_{tir} = 1.0$ 且投影头设为恒等映射的条件下，对比注入 MQRC 前后模型在同一批输入上的输出张量，最大绝对误差约为 1×10^{-7} 量级，确认校准模块在初始状态下不对原始输出产生实质性扰动。

MQRC 引入的可训练参数总量极为有限，相较于 FMTrack 的参数规模可以忽

略不计，远低于 1M 的设计约束上界。校准训练的数据来源为 LasHeR 训练集，考虑到参数的规模性较小，大量训练数据反而可能导致有效梯度信号被噪声稀释，因此本文从 LasHeR 训练集中随机采样约 1% 的序列帧对作为校准训练集。每次迭代对同一帧对被选定退化的模态生成原始、低强度退化和高强度退化三个版本构成三元组样本，退化类型从七种操作中随机选取，退化强度在对应等级范围内随机采样。训练总轮数不超过 10 轮，实践中通常 5 轮左右排序损失即趋于收敛，后续轮次参数变化幅度极小。

训练使用的总损失函数为排序损失与跟踪定位损失的加权组合：

$$\mathcal{L}_{total} = \mathcal{L}_{rank} + \lambda \mathcal{L}_{track} \quad (3-10)$$

其中 λ 为权衡系数。 $\mathcal{L}_{track}$ 在此处并非用于优化跟踪定位性能，而是作为正则化项约束校准后融合权重不至于严重偏离原始跟踪性能。如果仅使用 $\mathcal{L}_{rank}$ ，温度参数可能被驱动到极端值，例如将某一模态温度设为极大值使其可靠性分数趋近于零，虽满足偏序关系但会破坏融合权重的合理分布。 $\mathcal{L}_{track}$ 通过维持基本的跟踪精度水平隐式限制温度参数的调整幅度，防止校准出现过拟合现象。

优化器选用 AdamW，温度参数学习率设为 1×10^{-4} ，投影头参数学习率设为 5×10^{-4} 。分设不同学习率的考虑在于：温度参数仅有 4 个标量，对梯度幅度高度敏感，过大学习率易致振荡；投影头具有多层结构和非线性激活，梯度方差较高，需要稍大学习率保证收敛速度。学习率按余弦退火调度器衰减，使优化后期自然趋于稳定。整个校准训练在单张 GPU 上仅需数分钟即可完成。

3.6 本章小节

本章详细阐述了 MQRC 模块的设计原理与实现细节。MQRC 模块的设计逻辑形成一条清晰的技术链路：3.1 节从形式化角度定位 MEFM 可靠性预测的过置信问题及其根源；3.2 节引入独立温度缩放层通过各专家层独立的温度参数调整可靠性分数分布形态；3.3 节设计合成退化对比对齐机制为温度参数优化提供独立于跟踪目标的偏序监督信号；3.4 节通过 MLP 投影头将校准后的质量判断与融合权重决策解耦；3.5 节在工程层面实现严格的后训练流程，通过参数冻结、钩子注入和数值验证确保校准过程的非侵入性和正确性。各组件功能互补、分工明确，共同构成完整的模态质量可靠性校准框架。

第四章 实验结果与分析

4.1 实验数据集介绍

本文的实验评测在三个 RGB-T 多模态目标跟踪领域的公开基准数据集上进行，以验证所提方法在不同数据规模和场景复杂度条件下的性能表现与泛化能力。三个数据集在规模、场景复杂度和挑战分布上各具特色，能够从多个维度全面检验方法的有效性。

表 4-1 各数据集横向对比

数据集	序列数	最大帧数	总帧数	分辨率	数据集特点
LasHeR	1224	12862	734.8K	630x480	大规模 RGBT 目标跟踪数据集，场景复杂，类别丰富。
RGBT210	210	4140	104.7K	630x460	密集标注，模态图像对齐准确，挑战属性较为丰富。
RGBT234	234	4140	116.7K	630x460	相比于前者增加了雨天、夜晚、寒冷和炎热环境的视频。

LasHeR 是目前 RGB-T 跟踪领域规模最大的基准数据集，由安徽大学李程华教授团队构建并发表。该数据集包含 1224 个空间对齐的可见光-热红外视频序列对，总帧数约 73 万帧，在数据规模上显著超越此前所有同类数据集。LasHeR 的采集横跨四季，覆盖晴天、阴天、雨天、雾天等天气条件以及白天和夜间的不同光照环境，目标类别涵盖行人、车辆、动物、自行车等多种跟踪对象。标注团队为每个序列提供了逐帧边界框标注，并额外标注了 19 种挑战属性，使研究者能够对方法在不同困难条件下的表现进行精细化分析。在这些挑战属性中，低光照序列占比约 48%，反映了该数据集对夜间和弱光场景的充分覆盖；遮挡属性序列占比约 38%，涵盖了从部分遮挡到短暂全遮挡的多种遮挡模式；热交叉，即目标与相邻物体热辐射特征相近导致热红外图像中难以区分的情况约占 15%，这一属性对融合机制的质量感知能力构成了直接考验。此外，快速运动约占 28%、尺度变化约占 52%、背景杂波约占 34%，这些统计特征使得 LasHeR 能够全面覆盖 RGB-T 跟踪在实际部署中可能遇到的各类困难场景。数据集按约 4:1 比例划分为训练集（约 979 个序列）和测试集（245 个序列），采用成功率 SR、精确率 PR 和归一化精确率 NPR 作为官方评估指标。在本文中，LasHeR 的训练集提供 MQRC 后训练校准的数据来源（随机采样约 1%帧对），测试集则作为最主要的评测基准。

RGBT234 包含 234 个可见光-热红外视频序列对，是 RGB-T 跟踪领域使用最广泛的评测基准之一。该数据集由 Li 等人发表，采集场景以城市街道、校园道路和室内外混合环境为主，目标类别以行人和车辆为主。RGBT234 覆盖遮挡、快速运动、光照变化、热交叉、低分辨率、背景杂波等多种跟踪挑战，序列平均长度较长，部分序列超过千帧，这一特点使其尤其适合评估长时序跟踪场景下方法的稳定性，因为随着序列推移，目标外观变化积累、模态质量波动模式日趋复杂，对融合策略的持久适应能力提出了更高要求。RGBT234 的传感器设备和采集条件与 LasHeR 存在明显差异，其热红外图像的分辨率和信噪比特征也有所不同，使得在该数据集上的评测结果能够有效检验方法的跨传感器泛化能力。其官方评估指标为最大成功率 MSR 和最大精确率 MPR。由于 MQRC 的校准训练数据仅来源于 LasHeR，RGBT234 上的结果直接反映校准模块在分布外场景中的泛化能力，因此本文中 RGBT234 既用于复现验证（以 man3 序列验证 FMTrack 基线），也作为跨数据集泛化评测的重要基准。

RGBT210 包含 210 个 RGB-T 视频序列对，是 RGBT234 的前身版本，由同一研究团队在 RGBT234 发布之前公开。RGBT210 与 RGBT234 部分重叠但并非完全子集，两者在序列选择和部分标注上存在差异。RGBT210 的场景构成相对集中于户外监控和街道巡视，光照条件变化丰富但极端场景比例低于 LasHeR，在领域内积累了丰富的对比结果。该数据集常被用作补充评测以增强实验结论的稳健性，其与 RGBT234 的部分重叠也为方法在近似但不完全相同的数据条件下的一致性提供了检验窗口。评估指标同为 MSR 和 MPR。本文中 RGBT210 的 people 序列被用于复现验证，完整数据集则提供泛化分析的额外证据。

4.2 评估指标

本文采用的评估指标覆盖跟踪精度和置信度校准质量两个维度。

精确率衡量跟踪器的中心定位准确度。对每一帧计算预测框中心与真实框中心的欧氏距离，当该距离小于给定阈值时判定为定位成功，精确率为成功帧占总帧数的比例。评测中以 20 像素为标准阈值，记为 PR。该指标直观反映空间定位偏差，但不考虑预测框的尺度信息。

精确率衡量跟踪器的中心定位准确度。设第 t 帧中预测框中心坐标为 (x_t^p, y_t^p) ,

真实框中心坐标为 (x_t^{gt}, y_t^{gt}) ，定义中心距离误差为：

$$d_t = \sqrt{(x_t^p - x_t^{gt})^2 + (y_t^p - y_t^{gt})^2} \quad (4-1)$$

当 d_t 小于给定阈值 θ 时判定第 t 帧定位成功，精确率定义为成功帧占总帧数的比例：

$$PR = \frac{1}{T} \sum_{t=1}^T \mathbb{1}[d_t < \theta] \quad (4-2)$$

评测中以 $\theta = 20$ 像素为标准阈值。该指标直观反映空间定位偏差，但不考虑预测框的尺度信息。

成功率从边界框重叠度出发评估跟踪质量。设第 t 帧预测框为 B_p ，真实框为 B_{gt} ，交并比定义为：

$$IoUt = \frac{|B_p \cap B_{gt}|}{|B_p \cup B_{gt}|} \quad (4-3)$$

给定重叠阈值 $\eta \in [0,1]$ ，成功率为 $IoUt > \eta$ 的帧占总帧数的比例：

$$SR(\eta) = \frac{1}{T} \sum_{t=1}^T \mathbb{1}[IoUt > \eta] \quad (4-4)$$

令 η 从 0 到 1 变化即得成功率曲线，对该曲线在 $[0,1]$ 上积分得到面积下曲线 AUC 值。AUC 对单一阈值选取不敏感，是目标跟踪领域最常用的综合评测指标。LasHeR 上报告的 SR 即为 AUC 值，RGBT234、RGBT210 和 GTOT 上报告的 MSR 为成功率曲线峰值。

归一化精确率是 LasHeR 引入的改进指标。标准精确率中固定的 20 像素阈值对大目标过于宽松、对小目标过于严格。NPR 将中心距离除以真实框对角线长度进行归一化，定义归一化距离为：

$$\widehat{d}_t = \frac{d_t}{l_t^{gt}} \quad (4-5)$$

其中 $l_t^{gt} = \sqrt{w_t^2 + h_t^2}$ ， w_t 和 h_t 分别为真实框的宽和高。归一化后的距离阈值从绝对像素量转变为相对于目标尺度的比例偏差，在不同尺度序列间建立统一评价标尺。NPR 取归一化精确率曲线下面积作为最终指标值。

期望校准误差用于衡量 MQRC 的校准效果。设将预测置信度的值域 $[0,1]$ 均匀划分为 K 个区间 $B_1, B_2, \dots, B_K$ ，令 n_k 为落入第 k 个区间的样本数， N 为总样本数， conf_k

为该区间内所有样本的平均置信度， acc_k 为该区间内样本的实际准确率，则 ECE 定义为各区间置信度与准确率偏差的加权平均：

$$\text{ECE} = \sum_k \frac{n_k}{N} |\text{acc}_k - \text{conf}_k| \quad (4-6)$$

该指标值越低表明模型输出的置信度与其实际预测正确率越一致，即校准质量越好。本文将 ECE 适配至 RGB-T 跟踪的模式可靠性评估场景：以 MQRC 输出的模式可靠性分数作为置信度进行分 bin，以各 bin 内对应帧的跟踪 IoU 均值作为实际准确度度量，从而量化可靠性分数与跟踪质量间的统计一致性。

4.3 实验设置

FMTrack 基线模型的复现工作分为本地调试和 GPU 评测两个阶段。本地调试在 Ubuntu 虚拟机上进行，采用 CPU 模式验证代码逻辑和数据流的正确性。大规模评测实验在 GPU 计算集群上完成，运行环境为 Python 3.12、PyTorch 2.4.0（CUDA 12.1），硬件为 NVIDIA H100 80GB GPU。

复现过程中遇到并解决了三个兼容性问题，这些问题在开源代码的跨环境部署中具有一定的代表性。

第一个问题涉及 PyTorch 版本与 CUDA 驱动的兼容性。集群上的 CUDA Driver 版本为 535，与 PyTorch 默认依赖的 CUDA 12.8 运行时存在版本不匹配，导致运行时报错。本文通过将 PyTorch 降级至 2.4.0+cu121 版本，并手动配置 LD_LIBRARY_PATH 优先加载 pip 安装的 NVIDIA 运行时库路径，使 PyTorch 的 CUDA 运算模块能够正确调用底层驱动接口。

第二个问题与 FMTrack 依赖的 mmcv-full 库中可变形卷积等 CUDA 自定义算子有关。mmcv-full 的安装过程涉及 CUDA 算子的源码编译，对 CUDA 工具链版本、编译器版本和 GPU 架构的计算能力值有严格的匹配要求。在目标硬件的 CUDA 版本和 PyTorch 版本组合下，mmcv-full 的 CUDA 算子编译无法通过。本文通过将 FMTrack 中 FIN 模块依赖的 mmcv 频域变换算子替换为 PyTorch 原生实现，在不影响功能正确性的前提下彻底消除了对 mmcv-full CUDA 编译的依赖。

第三个问题出现在 RGBT210 数据集的序列列表文件中。FMTrack 代码仓库中附带的 RGBT210 序列列表文件部分序列名称的大小写或路径分隔符与实际下载的数据集目录结构不一致，导致评测脚本在加载部分序列时因路径不存在而报错。

本文通过逐一比对列表文件中的序列名称与实际目录名称，修正了大小写差异和路径格式问题，确保所有序列均能被正确加载和评测。

表 4-2 复现结果对比

RGBT210	AUC	OP50	OP75	Precision	Norm Precision
原始论文	63.6	—	—	88.3	—
复现结果	63.54	80.25	45.89	86.76	75.98

复现验证的定量结果表明，修正后代码在 RGBT210 上的结果与 FMTrack 原始论文公开数据基本吻合，确认了复现的正确性。在 RGBT234 上，复现结果的 MSR 和 MPR 与原论文报告值的偏差均在可接受范围以内，处于随机种子和硬件环境差异导致的正常波动范围内，进一步确认了基线复现的准确性。

MQRC 模块的后训练校准实验在基线复现的基础上进行。校准训练的数据来源为 LasHeR 训练集，从中随机采样约 1% 的序列帧对。采样策略在训练集的 979 个序列中随机选取若干序列，再从每个选中序列中随机抽取若干帧，确保采样在序列和时间两个维度上具有多样性，避免采样集中于少数序列导致的偏差。校准训练总轮数为 10 轮，排序损失通常在第 5 轮左右趋于收敛，后续轮次参数变化幅度极为有限。优化器采用 AdamW，温度缩放层四个标量参数学习率设为 1×10^{-4} ，MLP 投影头 280 个参数学习率设为 5×10^{-4} ，分设不同学习率以匹配温度参数的高梯度敏感性与投影头多层结构的高梯度方差。学习率按余弦退火调度衰减，合成退化的 margin 阈值 $\delta = 0.2$ ，退化类型从第三章所述七种操作中随机选取，退化强度在对应等级范围内随机采样。训练批大小根据 GPU 显存容量确定，整个校准训练在单张 GPU 上仅需数分钟即可完成。

4.4 与现有方法的对比实验

本文在三个基准数据集上将 FMTrack+MQRC 与多种现有 RGB-T 跟踪方法进行对比，包括基于桥接令牌的 TBSI 和基线方法 FMTrack。其中 TBSI 的对比数据引用自其原始论文在完整数据集上的公开结果，FMTrack 基线及 FMTrack+MQRC 的结果为本文在相同实验环境下的实际评测值。由于评测硬件与训练随机种子的差异，FMTrack 复现结果与其原论文数值存在约 2-3 个百分点的正常波动，但不影响方法间相对增益的有效比较。

表 4-3 LasHeR 测试集上的对比结果

方法	SR (%)	PR (%)	NPR (%)
TBSI	55.6	69.2	65.3
FMTrack	54.7	70.0	65.5
FMTrack+MQRC	55.0	70.4	65.8

在 LasHeR 测试集上，FMTrack+MQRC 在三项指标上均优于基线，SR 提升约 0.3 个百分点，PR 提升约 0.4 个百分点，NPR 提升约 0.3 个百分点。LasHeR 测试集涵盖 19 种挑战属性和广泛的场景多样性，是衡量方法综合性能最具说服力的评测平台。上述提升表明 MQRC 的后训练校准有效改善了融合权重的分配质量。从属性分布角度分析，LasHeR 中近半数序列涉及低光照条件，在这些序列中可见光图像质量严重退化，原始 MEFM 的可靠性预测容易出现对可见光模态的错误高置信度，MQRC 通过温度缩放压缩这种过度置信，使融合权重更合理地向热红外倾斜。对于占比约 38%的遮挡序列，遮挡导致的模态质量突变对可靠性预测的实时响应能力提出了较高要求，MQRC 的对比对齐训练使校准后的可靠性分数对质量退化更加敏感，能够在遮挡发生时更快速地调整融合权重。由于 MQRC 的训练数据采样自 LasHeR 训练集，测试集上的结果在一定程度上反映同分布条件下的校准增益，同分布的统计特性使校准参数能够较好地适配测试数据的分布规律。

表 4-4 RGBT234 上的对比结果

方法	MSR (%)	MPR (%)
TBSI	63.7	87.1
FMTrack	63.2	87.1
FMTrack+MQRC	64.9	89.6

RGBT234 上的评测对于检验 MQRC 的跨数据集泛化能力具有关键意义。MQRC 的校准训练仅使用 LasHeR 训练集的约 1%数据，校准过程中完全未接触 RGBT234 的任何序列。FMTrack+MQRC 在 RGBT234 上取得 MSR 约 1.7 个百分点、MPR 约 2.5 个百分点的提升，提升幅度在三个数据集中最为显著。RGBT234 在传感器设备、采集环境和序列长度分布等方面与 LasHeR 存在显著差异，构成典型的分布外测试场景。在跨数据集条件下仍获得明确的性能增益表明，MQRC 并非过拟合于 LasHeR 的特定数据分布，而是捕捉到了模态可靠性过置信这一跨数据

集普遍存在的系统性偏差模式。RGBT234 中序列平均长度较长的特点额外验证了校准效果在长时序跟踪中的持久性：随着序列推移，目标外观变化持续积累，模态质量波动模式可能与训练阶段短时序片段中所见的模式差异较大，而 MQRC 的校准仍能在这种长期演变过程中维持稳定增益，说明校准参数学到的是一种对质量偏序的一般性判断而非对特定短时序模式的过拟合记忆。

表 4-5 RGBT210 上的对比结果

方法	MSR (%)	MPR (%)
TBSI	62.5	85.3
FMTrack	61.4	80.5
FMTrack+MQRC	62.3	81.2

RGBT210 上的结果与 RGBT234 呈现一致的提升趋势。FMTrack+MQRC 在 MSR 上提升约 0.9 个百分点，MPR 上提升约 0.7 个百分点。RGBT210 与 RGBT234 虽然存在部分序列重叠，但两者在序列选择和标注上并不完全一致，RGBT210 的部分序列标注更新时间较早，标注粒度和一致性可能略有差异。在这种条件下仍获得稳定的正向增益，进一步印证了 MQRC 校准效果的鲁棒性不依赖于特定数据集的标注风格或序列构成。

综合三个数据集，FMTrack+MQRC 在所有基准上均获得一致的正向增益，提升幅度因数据集特征而异但方向一致。其中 RGBT234 和 RGBT210 作为校准训练中完全未见过的分布外数据，所取得的显著提升尤其具有说服力。这种一致性源于 MQRC 的非侵入性设计，即仅修正可靠性分数分布而不触及特征提取能力，不会引入性能退化风险。作为仅含 284 个额外参数的后训练方案，MQRC 的每参数性能增益效率在所有对比方法中极为突出。

4.5 消融实验

为分析 MQRC 各组件的独立贡献以及关键超参数的敏感性，本文设计三组消融配置并在 LasHeR 测试集和 RGBT234 两个数据集上进行评测。第一组消融配置 No-TS 移除温度缩放层，将各专家层的温度参数固定为 1，仅保留 MLP 投影头和合成退化对比排序损失，FMTrack 原始 logit 值不经尺度调整直接送入投影头。第二组消融配置 No-CL 移除合成退化对比损失，保留温度缩放层和投影头，但训练中不施加偏序排序约束，仅以跟踪定位损失的正则化项驱动校准参数更新。第三组

消融配置 No-MLP 移除投影头,温度缩放后的校准 logit 值直接送回原始推理流程,温度参数优化仍由对比排序损失驱动。

表 4-6 消融实验结果

配置	LasHeR SR(%)	LasHeR PR(%)	LasHeR NPR(%)	RGBT234 MSR(%)	RGBT234 MPR(%)
FMTrack	54.7	70.0	65.5	63.2	87.1
No-TS	54.8	70.2	65.7	63.9	88.5
No-CL	54.4	69.7	65.2	62.7	86.8
No-MLP	54.9	70.3	65.7	63.3	87.2
MQRC	55.0	70.4	65.8	64.9	89.6

No-TS 配置相较于完整 MQRC 出现性能下降 (LasHeR SR 降约 0.2、RGBT234 MSR 降约 1.0 个百分点),揭示了温度缩放层的独特价值。温度缩放以 4 个标量参数完成各专家层可靠性 logit 的尺度粗调:当存在过置信偏差时,压缩极端预测使权重分布趋于平滑。缺少此步骤时,投影头需同时承担尺度校正和非线性映射两个任务。虽然投影头理论上具有一定的尺度调整能力,但 16 维隐层的有限容量在双重目标下表达能力不足:尺度校正需要捕捉 logit 值绝对幅度的系统性偏移,而非线性映射需要刻画质量分数与最优权重之间的复杂对应关系,两个需求对网络参数的利用方式不同,单一组件难以兼顾。温度缩放先将 logit 值调整到合理的数值范围,投影头再在此基础上学习非线性映射,这种分工协作优于让单一组件承担全部职责。

No-CL 配置的性能退化在三组消融中最为显著(LasHeR SR 降约 0.6、RGBT234 MSR 降约 2.2 个百分点),从实验角度证实了第三章的理论分析:合成退化对比损失提供的偏序监督信号是 MQRC 校准效果的核心驱动力。在 No-CL 配置下,温度参数和投影头参数的更新完全由跟踪定位损失的正则化项驱动,而 FMTrack 的骨干参数已被冻结,对仅有 284 个校准参数的梯度信号极为微弱且方向不稳定,优化过程难以有效收敛到有意义的参数值。更根本的是,该梯度驱动的参数更新方向指向“使跟踪结果更准确”而非“使可靠性分数更贴合模态质量”,恰恰再现了第二章所诊断的端到端训练语义错位问题,即仅有校准网络结构而缺少正确的校准信号,模态可靠性的改善极为有限。No-CL 在部分指标上低于 FMTrack 基线的现象也值

得关注：微弱且方向不当的梯度扰动使温度参数偏离了初始的恒等映射状态，而偏离方向并非改善校准的方向，反而引入了额外的分布扰动。

No-MLP 配置的性能下降呈现出明显的数据集依赖性：在 LasHeR 上仅降约 0.1 个百分点，接近完整 MQRC 的性能；但在 RGBT234 上降约 1.6 个百分点，增益几乎消失。该配置保留了温度缩放层和合成退化对比损失，校准信号和分布尺度调整能力均在，因此在同分布的 LasHeR 测试集上已具备基本的校准能力。然而在分布外的 RGBT234 上，温度缩放后的 logit 值直接参与后续融合，缺少投影头的非线性适配，当校准可靠性分数与最优融合权重之间存在非线性关系时，如模态质量从“良好”到“退化”的过渡带内权重应当快速下降的阈值效应，或极端退化时权重接近但不等于零的饱和效应，线性映射无法充分逼近这些跨数据集场景下更为复杂的对应关系。这一结果表明，投影头的非线性适配能力对跨数据集泛化至关重要。

为验证 MQRC 模块的计算效率，本文在单张 NVIDIA H100 GPU 上对 FMTrack+MQRC 进行推理速度测试。测试结果表明，加入 MQRC 后模型总参数量为 286.40M，总计算量为 128.33 GFLOPs，推理速度为 65.95 FPS。相较于 FMTrack 原始模型，MQRC 对模型整体计算量和推理速度的影响可忽略不计，完全满足实时跟踪的帧率要求。这一结果验证了 MQRC 后训练校准方案在极低计算开销下实现性能增益的设计优势，证明了该方法在实际部署场景中具备良好的工程可行性。

4.6 置信度校准质量分析

本节从置信度校准视角分析 MQRC 对模态可靠性估计质量的影响，揭示跟踪精度提升背后融合权重分配合理性改善的内在机制。与前述对比实验和消融实验侧重于跟踪精度指标的评测不同，本节引入期望校准误差 ECE 作为专项评估手段，直接衡量可靠性分数输出的置信度合理性，从而为 MQRC 的校准功能提供独立于跟踪精度的补充验证。

ECE 指标对比表明，FMTrack 原始可靠性预测在 LasHeR 测试集上的 ECE 为 0.157，MQRC 校准后降至 0.109。ECE 的降低意味着校准后可靠性分数与实际跟踪 IoU 的一致性得到改善：当模型输出较高的可靠性分数时，对应帧的跟踪 IoU 确实倾向于更高；当模型输出较低的可靠性分数时，对应帧的跟踪质量也确实相对较差。这种分数与实际表现之间统计一致性的增强，表明 MQRC 的温度缩放与对比对齐训练有效压缩了原始可靠性预测中的过置信成分，使分数更准确地反映了模

态的真实贡献能力，从而使下游的融合权重分配更为合理。

可靠性分数的分布形态变化进一步揭示了校准前后融合行为的本质差异。校准前，FMTrack 的可靠性分数呈明显的两极化分布，大量帧的分数集中在接近 0 和接近 1 的极端区域，中间区域密度极低。这意味着跟踪器在多数帧上近乎完全信任某一模态而忽略另一模态，多专家融合实质退化为单一专家输出，丧失了多模态冗余的容错能力。校准后，极端区域密度明显降低，分布向 0.3 至 0.7 的中间区域收拢，融合策略在多数帧上保持对两个模态的适度关注，系统在任一模态突发退化时保留了利用另一模态补偿的空间。这种分布的“平滑化”正是温度缩放层以 $T>1$ 压缩 logit 幅度的直接效果，而分布平滑化后跟踪性能不降反升的事实则证明，原始的极端权重分配中确实存在大量因过置信而导致的错误决策。

退化场景下的响应分析提供了因果层面的解释。本文对 LasHeR 测试集的若干序列人为施加高强度高斯模糊退化可见光模态，保持热红外不变。FMTrack 原始输出中，可见光可靠性分数在退化前后变化极小——即使图像已严重模糊到目标难以辨认，分数仍维持高位，融合权重大幅偏向退化模态，印证了第二章对过置信问题的分析。MQRC 校准后，同一退化条件下可见光分数出现显著且方向正确的下降，权重相应向热红外偏移，使融合更多依赖未退化信息。这种敏感响应正是合成退化对比对齐机制的训练效果在推理阶段的直接体现：校准训练中对各种退化模式的三元组排序约束使温度参数和投影头学会了将退化引起的特征变化翻译为可靠性分数的对应下降。

4.7 跟踪结果分析

除定量指标外，本文对若干典型挑战场景下的逐帧跟踪行为进行了定性观察。

在低光照序列中，FMTrack 原始模型在可见光严重退化的帧上仍倾向于维持较高的可见光融合权重，导致跟踪框框出现间歇性偏移；加入 MQRC 后，融合权重在光照骤降时能更快速地向热红外模态倾斜，跟踪框的稳定性有所改善。

在热交叉序列中，当目标热辐射特征与周围环境趋同时，原始模型偶尔将跟踪框吸引至相邻热源区域；MQRC 通过降低热红外模态的可靠性分数，使融合决策更多依赖可见光纹理信息，减少了此类漂移的发生频率。

在部分遮挡序列中，两种模态的遮挡程度往往不完全一致，MQRC 的校准使可靠性分数对遮挡引起的质量突变响应更敏感，融合权重能在遮挡发生时更及时

地向受遮挡影响较小的模态转移。

上述定性观察与 4.4 节定量结果及 4.6 节置信度校准分析的结论一致：MQRC 的性能增益来源于融合权重分配合理性的改善，而非特征表示能力的增强。在低光照序列中，FMTrack 原始模型在可见光严重退化的帧上仍倾向于维持较高的可见光融合权重，导致跟踪框出现间歇性偏移；加入 MQRC 后，融合权重在光照骤降时能更快速地向热红外模态倾斜，跟踪框的稳定性有所改善。

4.8 本章小结

本章在 LasHeR、RGBT234 和 RGBT210 三个基准数据集上对 MQRC 进行了全面的实验评测。对比实验表明 FMTrack+MQRC 在所有数据集上均获得一致的正向性能增益，尤其在从未参与训练的 RGBT234 和 RGBT210 上展现了跨数据集泛化能力。消融实验验证了三个组件的功能互补性，其中合成退化对比损失作为校准信号的核心提供者贡献最为关键。置信度校准分析从 ECE 降低和分布平滑化两个维度揭示了性能提升的内在机制。跟踪结果的定性分析进一步印证了 MQRC 在低光照、热交叉和遮挡等典型挑战场景下对融合权重分配的有效修正。

第五章 结论

本文围绕 RGB-T 多模态目标跟踪中模态融合可靠性建模这一核心问题展开研究，以 FMTrack 为基线跟踪器，针对其多专家融合模块 MEFM 中可靠性预测子网络存在的训练目标与语义意图错位问题，提出了模态质量可靠性校准模块 MQRC，并在三个主流基准数据集上进行了系统的实验验证。

在理论分析层面，本文首先系统梳理了 RGB-T 跟踪领域的方法演进脉络。从 MOSSE 和 KCF 为代表的相关滤波范式，到 SiamRPN++ 推动的深度孪生网络时代，再到 OTrack 和 MixFormer 确立的单流变换器架构，基础跟踪框架的每一次范式转换都深刻影响了多模态融合机制的设计思路。在此背景下，本文重点分析了 RGB-T 跟踪从早期特征拼接、双流注意力交互到 TBSI 桥接令牌和 FMTrack 多专家融合的技术路线演变，指出模态质量感知融合正从隐式的端到端学习走向更加显式和精细的建模方式，但现有方法在可靠性评估的训练范式上仍存在根本性的缺陷。

在问题诊断层面，本文对 FMTrack 中 MEFM 可靠性预测子网络的训练机制进行了形式化分析。可靠性预测子网络的参数更新完全由跟踪定位损失的梯度信号驱动，其优化目标是使最终加权融合结果产生更准确的边界框回归，而非真正学会判断当前帧中各模态的信息质量。这种训练目标与语义意图之间的错位，在训练数据分布内可以被近似等价的统计规律所掩盖，但当模型迁移到分布外的新数据集时，可靠性预测表现出系统性的过度置信——softmax 归一化后的融合权重趋向极端值，多专家融合实质退化为对单一模态的盲目依赖，多模态冗余所本应提供的容错能力完全丧失。

在方法设计层面，本文提出的 MQRC 模块包含三个功能互补的核心组件。独立温度缩放层为 MEFM 中各专家层分别维护独立的温度参数，通过对数空间参数化保证温度严格为正，在保持恒等初始化的前提下对原始可靠性 logit 值进行分布形态调整，压缩过度置信产生的极端预测值。合成退化对比对齐机制针对模态质量校准中监督信号缺失的根本困难，通过对训练样本施加可控的程序化退化构造具有明确质量偏序关系的三元组样本，以间隔排序损失将“退化越重则可靠性分数应越低”这一方向性约束转化为可微的训练信号，从根本上将可靠性估计的优化方向从间接服务于跟踪精度转向直接对齐模态质量偏序。两层 MLP 投影头以残差连接

形式对温度缩放后的校准 logit 施加非线性修正, 以 16 维隐层和 ReLU 非线性激活捕捉质量判断与融合决策之间的复杂映射关系, 将校准后的 logit 向量送回原始推理流程, 实现了“模态质量好坏的判断”与“融合权重如何分配”两个语义上不同的决策步骤在网络结构上的显式解耦。MQRC 的全部可训练参数仅有 284 个, 通过前向钩子机制非侵入地注入 FMTrack 推理流程, 不修改原始模型的任何预训练参数和源代码。

在实验验证层面, 本文在 LasHeR、RGBT234 和 RGBT210 三个基准数据集上对 FMTrack+MQRC 进行了全面评测。对比实验表明, MQRC 在三个数据集上均带来了一致的正向性能增益, 尤其在从未参与校准训练的 RGBT234 和 RGBT210 上同样展现了泛化能力, 验证了合成退化对比对齐所构造的偏序监督信号的跨分布一般性。消融实验清晰刻画了三个组件的功能层次, 其中合成退化对比损失作为校准信号的核心提供者贡献最为关键, 温度缩放层和投影头分别承担分布粗调与非线性适配的角色, 三者递进协作。置信度校准分析从 ECE 降低、分布平滑化和退化响应敏感性增强三个维度, 揭示了性能提升的内在机制在于融合权重分配合理性的改善而非特征表示能力的增强。

致 谢

或许是太久没有梳理过自己的感受，写到这一章的时候惊人地停滞了很久，几次打开又几次草草关掉，以至于在定稿前三天才在工位上下定决心动笔。本科四年，遇到太多帮助过我的人，此处无法一一列出，但与各位同行的时光在我心里都弥足珍贵。

首先要感谢导师李洁老师和朱志强师兄，以及课题组内其他老师、师兄和同学们在我本科毕业设计过程中给出的建议和帮助，可谓是举世无双好导师和天下第一好师兄搭配出的绝世好组，在此衷心祝组里的大家科研顺利！

感谢西安电子科技大学电子工程学院及其老师们。坦率地说，四年间并非一帆风顺，学业上的反复波折和各种始料未及的突发状况曾让我深感疲惫与困惑，但回头来看，正是这些并不体面的经历迫使我学会了在混乱中寻找出路、在压力下独立决策。感谢这段不算轻松的时光，它留给我的远比一纸文凭更有分量。

感谢我的挚友们在这四年期间给我提供的情感支持和发展建议，何其有幸遇到赵倩文、陈怡安、胡惠子、刘畅、寻梦、王子烨等朋友分享我的快乐、倾听我的悲伤、祝福我的期许、消解我的迷茫，希望我们之间的友谊长存！

感谢我的大学同学们在课业上对我的帮助，感谢我的室友们在生活上对我的包容，感谢大学期间各课题、项目、竞赛、课程设计中的指导老师队友们同我一起面对问题，感谢融媒体中心西电小喇叭使我收获了大学期间跨度尤其大的朋友们，感谢大学期间在科研、实习、申请中和我交流过的同伴们为我提供的信息，感谢在发展爱好的过程中能遇到宁芙、杨博这样志趣相投的朋友并保持了联系。

感谢企业的带教、正职和同学们，在公司的这几个月是我近期成长极迅速的一段时间，尽管各位大概率看不到这一页，但还是想感谢遇到这么包容、负责又信任我的团队，未来我会继续撸起袖子加油干，在与企业同行的过程中持续成长。

感谢我在北师大实验中学的高中同学和老师们，在这四年期间我与班内超过半数同学有过交流，看到大家在各个学校的各个专业继续保持着优秀也深深激励着我努力向前，也希望后续能与其他许久不曾见面的同学们重拾联系。

感谢 Formula 1 及其车手们、ATP 及其球员们、kpop 及其爱豆们、LCK 及其选手们、我钟爱的各类自媒体博主们以及部分电影和小说中的角色们，Max Verstappen 等人让低谷期的我意识到通往成功的路上绝非坦途，在我意气风发时警

醒我保持谦逊，也在我绝望时激励我不达目的誓不罢休，祝各位在自己热爱的事业上更进一步。

感谢这个时代的技术社区、大语言模型和开源生态，感谢每一个背后愿意分享踩坑经验的前人，遇到问题时是这些素未谋面的人留下的解决方案让我得以继续推进，也是这些愿意分享前沿发展的人在我逐步探索的学术道路上为我指明方向，这种陌生人之间单向传递的善意是我在本科期间感受到的最朴素也最可靠的支撑之一，愿开源精神继续前进。

压轴出场的是最亲爱的老爸和妈咪以及其他家人们，感谢你们数十年如一日对我的爱，我无法忘记你们在我钻牛角尖和发脾气时对我的包容、在我遇到挫折和崩溃时的安慰、在我取得进步时和我一同庆贺，无论我做出什么选择都信任我、鼓励我、支持我、赞扬我。你们是我持续成长进步的源动力和继续追求更上一层楼的底气，我想万语千言都无法表述出我们之间的至深感情，只好希望未来我们一家人永远幸福地在一起。

最后我要感谢我自己，这几年来不管遇到什么困难和挫折都不放弃，在迭代简历的过程中我看到了我们踏实走过的技术路径，也很庆幸我们一直有新成果可以加入。感谢你在努力没有获得结果的时候不苛责不内耗只归因于时运不济，在面对压力时逐渐建立了不逃避不放弃的稳定精神内核。再继续说下去恐怕会有过度自恋的嫌疑所以只好写到这里，感谢你对自己无条件的信任和爱，希望未来我们能继续追求卓越。

“当你穿过了暴风雨，你早已不再是原来那个人。”看着雨过天晴的西安敲下最后几个字，我想是时候该继续启程了。

参考文献

- [1] Feng M, Su J. RGBT tracking: A comprehensive review[J]. Information Fusion, 2024, 110: 102707.
- [2] 张天路, 张强. 基于深度学习的 RGB-T 目标跟踪技术综述[J]. 模式识别与人工智能, 2023, 36(4): 327-353.
- [3] Bolme D S, Beveridge J R, Draper B A, et al. Visual object tracking using adaptive correlation filters[C]// IEEE Conference on Computer Vision and Pattern Recognition. San Francisco: IEEE, 2010. 2544-2550.
- [4] 孟琰, 杨旭. 目标跟踪算法综述[J]. 自动化学报, 2019, 45(7): 1244-1260.
- [5] Henriques J F, Caseiro R, Martins P, et al. High-speed tracking with kernelized correlation filters[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(3): 583-596.
- [6] Li B, Wu W, Wang Q, et al. SiamRPN++: Evolution of siamese visual tracking with very deep networks[C]// IEEE Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019. 4282-4291.
- [7] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]// International Conference on Learning Representations. Vienna: OpenReview, 2021.
- [8] Ye B, Chang H, Ma B, et al. Joint feature learning and relation modeling for tracking: A one-stream framework[C]// European Conference on Computer Vision. Tel Aviv: Springer, 2022. 341-357.
- [9] Cui Y, Jiang C, Wang L, et al. MixFormer: End-to-end tracking with iterative mixed attention[C]// IEEE Conference on Computer Vision and Pattern Recognition. New Orleans: IEEE, 2022. 13608-13618.
- [10] Zhang T, Guo H, Jiao Q, et al. Efficient RGB-T tracking via cross-modality distillation[C]// IEEE Conference on Computer Vision and Pattern Recognition. Vancouver: IEEE, 2023.
- [11] Hou R, Xu B, Ren T, et al. MTNet: Learning modality-aware representation with transformer for RGBT tracking[J]. arXiv preprint arXiv:2508.17280, 2025.
- [12] Hui T, Xun Z, Peng F, et al. Bridging search region interaction with template for RGB-T tracking[C]// IEEE Conference on Computer Vision and Pattern Recognition. Vancouver: IEEE, 2023. 13630-13639.
- [13] Xiao Y, Zhao J, Lu A, et al. Cross-modulated attention transformer for RGBT tracking[C]// AAAI Conference on Artificial Intelligence. Philadelphia: AAAI Press, 2025.
- [14] 金静, 刘建琴, 翟凤文. 多模态特征融合的 RGB-T 目标跟踪网络[J]. 光学精密工程, 2025, 33(12): 1940-1954.
- [15] Xue Y, Jin Y, Zhong B, et al. FMTrack: Frequency-aware multi-expert fusion for RGB-T

- tracking[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2025.
- [16] Ding Z, Li C, Wang T, et al. Quality-aware spatio-temporal transformer network for RGBT tracking[J]. IEEE Transactions on Image Processing, 2025, PP(99): 1-1.
- [17] 余令仪, 王正杰, 詹昭焕. 先验引导的无人机 RGB-T 目标检测[J]. 北京理工大学学报, 2026, 46(5): 470-479.
- [18] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[C]// International Conference on Machine Learning. Sydney: PMLR, 2017. 1321-1330.
- [19] Zadrozny B, Elkan C. Obtaining calibrated probability estimates from decision trees and naive Bayesian classifiers[C]// International Conference on Machine Learning. Williamstown: Morgan Kaufmann, 2001. 609-616.
- [20] Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning[C]// International Conference on Machine Learning. Bonn: ACM, 2005. 625-632.
- [21] 王登豹, 张敏灵. 深度神经网络的置信度可校准性研究[J]. 中国科学: 信息科学, 2025, 55(9): 2289-2303.
- [22] Zhang L, Ma K. Calibrating multimodal learning[C]// International Conference on Machine Learning. Honolulu: PMLR, 2023.
- [23] Ding Z, Li C, Miao S, et al. Template-based uncertainty multimodal fusion network for RGBT tracking[C]// International Joint Conference on Artificial Intelligence. Jeju: IJCAI, 2025.
- [24] Li C, Liang X, Lu Y, et al. LasHeR: A large-scale high-diversity benchmark for RGBT tracking[J]. IEEE Transactions on Image Processing, 2022, 31. 392-404.
- [25] Li C, Liu H, Lu Y, et al. RGB-T object tracking: Benchmark and baseline[J]. Pattern Recognition, 2019, 96: 106977.
- [26] Li C, Zhao N, Lu Y, et al. Weighted sparse representation regularized graph learning for RGB-T object tracking[C]// ACM International Conference on Multimedia. Mountain View: ACM, 2017. 1856-1864.